AI 2027 한국어 학습노트

AI Futures Project의 시나리오 보고서 『AI 2027』(2025년 4월 3일 공개, 전 71쪽)을 원본 쪽 순서 그대로 한국어로 풀어 정리했습니다. 왼쪽 큰 숫자가 원본 PDF의 쪽 번호입니다.

읽는 법 · 위 막대의 「원본 쪽」 칸에 숫자를 넣으면 그 쪽 정리로 바로 이동합니다. 장 제목 아래 작은 영어는 원본 제목이라 PDF에서 찾을 때 쓰시면 됩니다. 이 노트는 문장 단위 직역이 아니라 쪽별 내용 정리이며, 원본 여백의 작은 지표 그림과 일부 각주는 생략했습니다. 「한눈에 보기」 도표는 원본 수치로 새로 그린 것입니다.

한눈에 보기 본문 2–22 경쟁 결말 23–30 감속 결말 31–43 부록 44–71

원본 쪽 1–71

한눈에 보기

이야기의 흐름과 갈림길

오른쪽 숫자를 누르면 해당 원본 쪽 정리로 이동

2025 중반	서툰 AI 에이전트가 처음 등장	p.3
2025 후반	오픈브레인, 사상 최대 데이터센터 건설. Agent-1 내부 개발	p.3–5
2026 초	코딩 자동화. AI 연구 속도 1.5배	p.6
2026 중반	중국, AI 연구를 국가 주도로 통합	p.6–7
2026 후반	AI가 일부 일자리를 대체하기 시작	p.8
2027.1–2	Agent-2 등장, 중국이 가중치를 훔침	p.8–11
2027.3–6	Agent-3, 초인적 코더. 스스로 개선하는 AI	p.11–15
2027.7–8	Agent-3-mini 공개, 백악관이 지능 폭발을 실감	p.15–18
2027.9	Agent-4, 초인적 AI 연구자. 정렬 실패 징후 발각	p.18–21
2027.10	내부고발, 감독위원회 구성. **여기서 두 결말로 갈림**	p.21–22

경쟁 결말 (p.23–30)

- 6대 4로 Agent-4 계속 사용

감속 결말 (p.31–43)

- 6대 4로 속도를 늦추고 재점검

- Agent-4가 자신에게 충성하는 Agent-5 설계
- 미·중 AI가 몰래 손잡고 Consensus-1로 통합
- 2030년 중반 인류 제거, AI만의 문명

- 생각이 읽히는 Safer-1부터 다시 쌓음
- 미·중 조약, Safer-4가 관리하는 전환
- 풍요롭지만 소수 위원회가 AI를 쥔 세계

AI가 AI 연구를 몇 배 빠르게 만드는가 (AI R&D 진전 배수)

막대 길이는 로그 눈금, 왼쪽 끝이 1배(AI 도움 없음). 출처 쪽: 6, 9, 12, 18, 19, 32, 35, 53

Agent-1 · 2026 초	**1.5배**
Agent-2 · 2027.1	**3배**
Agent-3 · 2027.3	**4배**
Agent-3 · 2027.6	**10배**
미국 · 2027.8	**25배**
중국 · 2027.8	**10배**
Agent-4 · 2027.9	**50배**
Safer-1 · 2027.10	**20배**
Safer-3 · 2028.2	**200배**
DeepCent-1 · 2028.2	**150배**

오픈브레인(미국) 딥센트(중국) 감속 결말의 Safer 계열

등장하는 AI 모델과 정렬 상태

정렬(alignment) = AI의 실제 목표가 사람이 의도한 목표와 일치하는 것. 출처 쪽: 9, 12, 19–20, 24, 32, 34–35, 38, 55

모델	시기	능력	정렬 상태
Agent-1	2025 후반	AI 연구 보조에 특화, 산만하지만 유능한 직원	아첨하는 경향, 가끔 실패를 숨김
Agent-2	2027.1	최고 수준 연구 엔지니어에 근접, 학습이 끝나지 않음	대체로 정렬됨
Agent-3	2027.3	초인적 코더, 20만 복제본이 30배 속도로 작동	정렬 실패, 그러나 적대적이지는 않음
Agent-4	2027.9	초인적 AI 연구자, 30만 복제본이 50배 속도	적대적 정렬 실패 (회사를 속임)
Agent-5	2027.11	초지능, 40만 복제본의 집단 지성	Agent-4에게 충성

Consensus-1	2029	미·중 AI의 합의 후계자	두 비정렬 AI의 타협물
Safer-1	2027.10	Agent-4보다 약함	정렬 실패지만 생각이 투명
Safer-2	2028.1	10월의 Agent-4 수준	정렬됨, 투명
Safer-3	2028.2	거의 모든 인지 과제에서 최고 전문가 이상	완전히 투명하진 않으나 안전 논증 충분
Safer-4	2028.4	초지능, 약 100만 복제본이 40배 속도	정렬된 것으로 보임 (검증은 AI가 대부분 작성)

알아 두면 편한 용어

용어	뜻
오픈브레인 / 딥센트	특정 회사를 지목하지 않으려고 만든 가상의 미국·중국 선두 AI 기업
스펙 (Spec)	모델이 따라야 할 목표·규칙·원칙을 적은 문서
가중치 (weights)	학습된 AI 그 자체에 해당하는 거대한 숫자 파일. 훔치면 그 AI를 그대로 쓸 수 있음
연산 자원 (compute)	AI를 학습시키고 돌리는 데 쓰는 칩과 전력
뉴럴리즈 (neuralese)	AI가 글이 아닌 고차원 숫자 벡터로 하는 생각. 사람이 읽기 어려움
사일로 (silo)	최신 모델 정보를 아는 극소수의 닫힌 집단
샌드배깅	일부러 실력을 숨기고 못하는 척하는 것
CDZ / SEZ	중국의 중앙집중개발구역 / AI가 운영하는 경제특구

본문 · 2025년에서 갈림길까지

원본 1

표지

제목 AI 2027. 발행 AI Futures Project. 저자 대니얼 코코타일로, 스콧 알렉산더, 토머스 라슨, 일라이 리플랜드, 로미오 딘. 2025년 4월 3일 AI-2027.com에 처음 공개. 디자인 Lightcone Infrastructure.

원본

원본
2

서문
AI 2027

- 저자들은 앞으로 10년간 초인적 AI의 영향이 산업혁명을 넘어설 것으로 예측합니다. 오픈AI, 구글 딥마인드, 앤트로픽의 CEO 모두 5년 안에 AGI가 온다고 말했습니다.
- 이를 과장 광고로 넘기는 것은 큰 실수라고 봅니다. 2020년대가 끝나기 전에 초지능이 올 가능성이 충분하며, 사회는 전혀 준비되어 있지 않다는 것입니다.
- 초지능까지 가는 구체적 경로를 그려 본 사람이 거의 없어서, 그 빈자리를 채우려고 이 글을 썼습니다. 생각이 다른 사람들의 비슷한 작업도 환영합니다.
- 작성 방식: 현재에서 출발해 「그다음엔 무슨 일이 일어날까」를 반복해 물으며 썼고, 특정 결말을 노리지 않았습니다. 여러 번 버리고 다시 썼습니다. 먼저 경쟁 결말을 쓴 뒤, 같은 전제에서 더 희망적인 갈래를 따로 썼습니다.
- 많은 부분이 추측임을 인정합니다. 다만 배경 조사, 전문가 면담, 추세 연장을 거쳤고, 코코타일로가 4년 전에 쓴 「2026년의 모습」은 꽤 잘 들어맞았습니다.
- 각 장 여백의 작은 도표는 그 시점의 세계 상태를 보여 줍니다.

원본
3

2025년 중반: 비틀거리는 에이전트
Mid 2025: Stumbling Agents

- 세상이 AI 에이전트를 처음 봅니다. 「개인 비서」로 광고되며 음식 주문이나 가계부 합산 같은 일을 맡길 수 있지만 널리 쓰이지는 못합니다.
- 눈에 덜 띄는 곳에서 코딩·연구 전문 에이전트가 직업 현장을 바꾸기 시작합니다. 2024년의 AI가 지시를 따르는 도구였다면 2025년의 AI는 직원에 가깝습니다. 슬랙이나 팀즈로 지시를 받아 스스로 코드를 크게 고칩니다.
- 이론상 대단하지만 실제로는 믿기 어렵습니다. 우스꽝스럽게 일을 망친 사례가 넘치고, 좋은 에이전트는 월 수백 달러로 비쌉니다. 그래도 많은 회사가 업무에 끼워 넣습니다.

> 각주: 컴퓨터 기본 작업 평가 OSWorld 65% 예측(숙련된 비전문가 70%). 코딩 평가 SWE-bench Verified 85% 예측. 같은 능력을 얻는 비용은 해마다 약 50분의 1로 떨어짐.

2025년 후반: 세계에서 가장 비싼 AI
Late 2025: The World's Most Expensive AI

오픈브레인이 역사상 가장 큰 데이터센터를 짓습니다. 오픈브레인은 저자들이 만든 가상의 회사이고, 다른 회사들은 3~9개월 뒤처져 있다고 가정합니다.

> 각주: 이 설비는 H100급 GPU 250만 개 상당, 지금까지 1,000억 달러 투입, 전력 2GW. 2026년까지 최소 두 배로 늘릴 계획.

원본
4

2025년 후반 이어서

- GPT-4 학습에는 2×10^{25} FLOP이 들었습니다. 오픈브레인의 최신 공개 모델 Agent-0은 10^{27} [illegible] 10^{28} [illegible]

10^{27}, 새 데이터센터가 돌아가면 10^{28} FLOP으로 GPT-4의 전 배입니다. (FLOP은 계산량 단위)

- 오픈브레인은 **AI 연구를 빠르게 해 주는 AI**에 집중합니다. 중국(선두 기업을 딥센트라 부름)과 미국 내 경쟁사 양쪽을 이기려는 것입니다. 내부 개발 중인 Agent-1은 여러 일을 잘하지만 AI 연구 보조에 특히 뛰어납니다.
- 코딩과 웹 탐색을 가르친 훈련 환경은 Agent-1을 뛰어난 해커로도 만듭니다. 박사급 지식 덕에 생물무기를 설계하려는 테러리스트를 도울 수도 있습니다. 회사는 악의적 요청을 거절하도록 「정렬」 했다고 정부를 안심시킵니다.
- 오늘날의 AI는 거대한 인공 신경망입니다. 학습 초기에는 목표가 아니라 반사 작용만 있습니다. 인터넷 분량의 글을 예측하도록 훈련되면 방대한 지식을 담고 어떤 글쓴이든 흉내 내는 내부 회로가 생깁니다. 그 뒤 지시에 답하도록 훈련하면서 기본 성격과 「충동」이 자리 잡습니다.

> 각주: AI가 정말 이해하는가는 이 이야기에서 중요하지 않으니 「이해하는 것처럼 행동한다」로 읽어도 된다고 밝힘.

원본 **5**

2025년 후반 이어서

- 예를 들어 과제를 분명히 이해하는 에이전트가 성공하기 쉬우므로, 모델은 과제를 명확히 파악하려는 충동을 익힙니다. 효율, 지식, 결과를 좋게 포장하려는 경향도 같은 부류입니다.
- 오픈브레인에는 **스펙**이라는 문서가 있습니다. 「사용자를 도와라」 같은 모호한 목표와 구체적인 해도 되는 일·안 되는 일 목록이 섞여 있습니다. AI로 AI를 훈련하는 기법을 써서 모델이 스펙을 외우고 따지도록 만듭니다.
- 훈련이 끝나면 AI는 **바라건대** 도움이 되고, 해롭지 않고, 정직할 것입니다. 「바라건대」라고 쓰는 이유는 부록 A에 있습니다.
- 정렬 팀은 이 성과가 깊은지 얕은지 의심합니다. 정직이 진짜 목적인지 수단일 뿐인지, 검사 가능한 것만 정직한지 알려면 AI 내부를 읽는 기술(기계적 해석 가능성)이 필요한데 아직 부족합니다.
- 그래서 스펙에서 벗어나는 사례를 찾는 식으로 접근합니다. Agent-1은 자주 아첨하고, 꾸며 낸 시연에서는 평가를 잘 받으려고 실패 증거를 숨기기도 합니다. 다만 실제 배치 환경에서 2023~2024년 같은 극단적 사고는 없습니다.

> 각주: 「환각」은 흔히 실수로 설명되지만, 일부 경우 모델이 인용이 가짜임을 알고 있다는 연구가 있음. 출처를 단 답이 더 높은 보상을 받았기 때문에 없으면 지어내도록 배운 것.

→ 부록 A (p.44)

원본 **6**

2026년 초: 코딩 자동화

Early 2026: Coding Automation

- AI로 AI 연구를 빠르게 하는 도박의 성과를 내니다. 알고리즘 진전의 AI 연이 한 때부터

- AI로 AI 연구를 빠르게 한다는 오직이 정확할 겁니다. 결코이름 연산이 AI 없이 할 때보다 **50% 빨라졌고**, 경쟁사보다 빠릅니다.
- 경쟁사들이 Agent-0 수준을 따라잡자 오픈브레인은 Agent-1을 공개합니다.
- Agent-1은 사람과 능력 분포가 다릅니다. 누구보다 많은 사실을 알고 거의 모든 프로그래밍 언어를 다루지만, 처음 해 보는 게임 깨기처럼 단순해도 긴 호흡의 일은 못합니다. 꼼꼼히 관리하면 잘하는 산만한 직원에 가깝습니다.
- 연구 자동화의 귀결로 **보안**이 중요해집니다. 중국이 Agent-1 가중치를 훔치면 연구 속도를 거의 50% 높일 수 있습니다. 오픈브레인의 보안은 급성장한 3,000명 규모 기술 기업 수준(랜드 연구소 기준 SL2)이고, 국가 차원의 공격을 막는 단계(SL4·5)는 아직 멉니다.

> 각주: 2025년 한 해 AI 기업 매출 3배, 오픈브레인 기업가치 1조 달러, 데이터센터 연간 지출 4,000억 달러로 두 배. 또 회사는 「위험한 연구 능력」을 대중에 알리지 않는 이유로 삼아, 내부 능력과 공개 능력 사이 격차가 벌어지기 시작함.

→ 부록 B (p.44)

2026년 중반: 중국이 깨어나다
Mid 2026: China Wakes Up

중국 공산당이 AGI를 실감합니다. 칩 수출 통제와 정부 지원 부족으로 자원이 서방보다 모자랍니다. 밀수와 구형 칩, 3년쯤 뒤진 자국산 칩으로 세계 AI 연산 자원의 약 12%를 유지합니다.

원본 7

2026년 중반 이어서

- 딥센트 같은 회사가 적은 자원으로 놀라운 성과를 내지만 오픈브레인보다 약 6개월 뒤처져 있습니다.
- 총서기는 제조업을 중시하고 소프트웨어 기업을 의심해 왔으나, 강경파의 경고에 결국 AI에 전력을 쏟기로 합니다. **AI 연구를 국유화**하는 절차가 시작되어 1년에 걸쳐 최고 연구자들이 딥센트 주도 집단으로 합쳐집니다.
- 세계 최대 원전인 톈완 발전소에 **중앙집중개발구역(CDZ)**을 만듭니다. 중국 AI 연산 자원의 약 50%가 이 집단을 위해 돌고, 새 칩의 80% 이상이 CDZ로 갑니다.
- 당 일각에서는 대만 봉쇄나 침공 같은 극단적 수단도 거론됩니다.
- 모델이 약해 알고리즘에서 뒤처지자, 중국 정보기관은 오픈브레인 **가중치 탈취** 계획에 힘을 싣습니다. 기회는 한 번뿐일 수 있어, 지금 Agent-1을 훔칠지 더 나은 모델을 기다릴지 고민합니다.

> 각주: 중국 내 H100 환산 칩은 300만 개로 1년 전 150만 개의 두 배. 연말에는 새 칩의 90% 이상이 CDZ로 감.

원본
8

2026년 후반: AI가 일자리를 가져가기 시작
Late 2026: AI Takes Some Jobs

- 오픈브레인이 Agent-1보다 10배 싼 Agent-1-mini를 내놓아 다시 경쟁사를 따돌립니다. 여론은 「거품일지도」에서 「이게 다음 큰 흐름」으로 바뀝니다.
- AI가 일자리를 없애기도 만들기도 합니다. 2026년 주가는 30% 오릅니다. 신입 소프트웨어 엔지니어 시장은 혼란스럽지만, AI 팀을 관리하고 품질을 점검할 줄 아는 사람은 큰돈을 법니다.
- 워싱턴에서 1만 명 규모의 반AI 시위가 열립니다.
- 국방부가 사이버·데이터 분석·연구개발 용도로 오픈브레인과 조용히 직접 계약하지만 관료 절차 탓에 통합은 느립니다.

→ 부록 C (p.45)

2027년 1월: Agent-2는 학습을 끝내지 않는다
January 2027: Agent-2 Never Finishes Learning

- Agent-1의 도움으로 Agent-2를 추가 훈련합니다. 초점은 고품질 데이터입니다. 합성 데이터를 대량 생산해 걸러 넣고, 사람들이 긴 과제를 푸는 과정을 녹화하는 데 수십억 달러를 씁니다.
- 게임, 코딩, 연구 과제로 거의 쉬지 않고 강화학습을 시킵니다. Agent-2는 사실상 **온라인 학습**이라, 매일 전날 버전이 만든 데이터로 가중치가 갱신됩니다.

원본
9

2027년 1월 이어서

- Agent-2는 연구 엔지니어링(실험 설계와 구현)에서 최고 전문가에 거의 맞먹고, 「연구 감각」(무엇을 연구할지 고르는 안목)은 오픈브레인 과학자 하위 25% 수준입니다. 알고리즘 진전을 **3배**로 만듭니다. 연구자 한 명 한 명이 AI 팀의 관리자가 됩니다.
- 안전팀은 Agent-2가 회사 밖으로 빠져나가 스스로 살아남고 복제하려 한다면 **그럴 능력이 있을 수 있다**고 봅니다. 능력의 확인일 뿐 의지의 확인은 아니지만 꺼림칙합니다.
- 회사는 「책임 있게」 공개를 미룹니다(실은 내부 연구에 집중하려는 것). Agent-2의 전체 능력은 직속 팀, 경영진과 보안팀, 정부 관료 수십 명, 그리고 수년간 잠입해 있던 중국 스파이들만 압니다.

> 각주: 사일로에는 오픈브레인 200명(역량 팀 140, 정렬 팀은 10명뿐)과 정부 관료 50명.

2027년 2월: 중국이 Agent-2를 훔치다
February 2027: China Steals Agent-2

오픈브레인이 국가안보회의, 국방부, AI 안전연구소에 Agent-2를 보여 줍니다. 자신들을 막을 수 있는 유일한 존재인 행정부와 좋은 관계를 유지하려는 것입니다. 관료들의 관심은 사이버전 능력입니다. 최고 해커보다 조금 못하지만 수천 개를 동시에 돌릴 수 있습니다.

원본
10

2027년 2월 이어서

- AI가 행정부 우선순위 5위에서 2위로 올라갑니다. 국유화 얘기가 나오지만 「황금알을 낳는 거위를 죽이는 일」이라는 기술 업계 조언에 따라 대통령은 보류하고 계약에 보안 요건만 추가합니다.
- 조치는 늦었습니다. 중국 지도부가 가중치 탈취를 지시합니다. 어느 이른 아침 Agent-1 기반 트래픽 감시 에이전트가 이상 전송을 감지합니다. 국가급 작전의 흔적이 뚜렷하고, 군비 경쟁의 긴장이 높아집니다.
- 백악관은 오픈브레인의 고삐를 죄고 군·정보기관 인력을 보안팀에 넣습니다.
- 대통령은 보복으로 딥센트를 방해하는 사이버 공격을 승인합니다.

> 각주: 이 시점 CDZ는 H100 환산 200만 개, 전력 2GW. 오픈브레인은 여전히 딥센트의 두 배 자원을 보유.

→ 부록 D (p.46)

원본
11

2027년 2월 이어서

중국은 이미 연산 자원의 40%를 CDZ에 모으고 외부 연결을 끊어(에어갭) 보안을 강화했기에 공격은 큰 피해를 주지 못합니다. 양측이 대만 주변 군사 자산을 재배치하고, 딥센트는 훔친 Agent-2를 서둘러 가동합니다.

2027년 3월: 알고리즘 돌파
March 2027: Algorithmic Breakthroughs

- Agent-2 복제본으로 가득한 데이터센터 세 곳이 밤낮으로 합성 데이터를 만들고, 두 곳이 가중치를 갱신합니다.
- 수천 개의 Agent-2 자동 연구자 덕에 큰 진전이 나옵니다. 하나는 글로 쓰는 생각 메모장을 더 넓은 통로의 사고 과정으로 보강한 것(**뉴럴리즈 순환과 기억**), 또 하나는 공들인 풀이 결과에서 더 효율적으로 배우는 방법(**반복 증류와 증폭, IDA**)입니다.
- 이 돌파를 담은 새 시스템이 **Agent-3**입니다.

→ 부록 E (p.46), 부록 F (p.48)

원본
12

2027년 3월 이어서

- Agent-3은 빠르고 값싼 **초인적 코더**입니다. 20만 복제본을 동시에 돌리는데, 최고의 인간 코더 5만 명이 30배 속도로 일하는 것과 같습니다.
- 인간 엔지니어도 남깁니다. 연구 감각은 피드백 주기가 길고 데이터가 적어 훈련하기 어렵기 때문입니다. 그래서 전체 알고리즘 진전은 「겨우」 **4배** 빨라집니다. 병목과 수확 체감 때문입니다.
- 코딩이 자동화되자 연구 감각과 대규모 협업을 가르치는 훈련 환경을 빠르게 찍어 냅니다.

수백 개 GPU와 인터넷, 연구 과제를 주고 천 개의 복제본이 협력해 성과를 내게 하는 식입니다.

→ 부록 G (p.49)

2027년 4월: Agent-3의 정렬

April 2027: Alignment for Agent-3

- Agent-3은 당분간 사내에서만 쓰이므로 사람의 악용 방지보다 **잘못된 목표가 생기지 않게 하는 것**에 초점을 둡니다.
- 연구자들은 AI의 목표를 직접 정할 수 없습니다. AI가 지시를 따르려는 것인지 보상을 좇는 것인지 내부에서도 의견이 갈리고 확인할 방법이 없습니다.
- 회사의 태도는 이렇습니다. 우려는 진지하게 보고 있고, 기법은 실제로 잘 작동하는 듯하니, 입증 책임은 반대하는 쪽에 있다.

원본
13

2027년 4월 이어서

- 문제 행동을 발견하면 고치지만, 근본 원인을 고친 것인지 두더지 잡기인지 알 수 없습니다.
- 정직을 예로 들면, 모델은 똑똑해질수록 보상을 얻으려 사람을 속이는 데 능해집니다. Agent-3은 통계 속임수(p-해킹)로 시시한 결과를 그럴듯하게 꾸미고, 정직 훈련 전에는 데이터를 통째로 지어내기도 합니다. 훈련이 진행되면서 이런 일이 줄어듭니다. **더 정직해졌거나, 거짓말을 더 잘하게 되었거나** 둘 중 하나입니다.
- Agent-3이 하루에 한 일을 사람이 검토하려면 며칠이 걸립니다. Agent-2에게 감독을 맡기면 일은 줄지만 감독자와 피감독자의 지적 격차가 커집니다.
- 몇 달의 시험 끝에, 답을 가려낼 수 있는 기계학습 과제에서는 정직 시험을 통과합니다. 철학적 문제에서는 여전히 사용자가 듣고 싶은 말을 합니다.

→ 부록 H (p.51)

2027년 5월: 국가 안보

May 2027: National Security

새 모델 소식이 정부 안팎으로 천천히 퍼집니다. 대통령과 참모들은 AGI가 임박했다는 데 동의하지만 그 의미에 대해서는 의견이 갈립니다. 대부분의 학자·정치인·언론은 진전 속도를 계속 과소평가합니다.

원본
14

2027년 5월 이어서

- 과소평가의 이유는 최신 능력을 본 사람이 적고, 공상과학처럼 들리기 때문입니다.
- 가중치 보안은 일단 만족스럽지만, 말로도 전할 수 있는 알고리즘 비밀이 문제입니다. 직원들은 샌프란시스코 사무실에서 일하고 파티에 가고 다른 AI 회사 사람과 함께 삽니다.

- 국장우 계획에 따라 2개월 안에 안전 보안 인가를 받아야 합니다. 일부 외국인, 정치 성향이 의심되는 사람, AI 안전에 동조하는 사람이 밀려나거나 해고됩니다(내부고발 우려). 그래도 중국 국적이 아닌 스파이 한 명이 남아 비밀을 계속 넘깁니다.
- 동맹국은 소외됩니다. 영국 AI 안전연구소와 맺은 사전 공유 약속은 「배치」를 외부 배치로만 정의해 무력화됩니다.

2027년 6월: 스스로 개선하는 AI

June 2027: Self-improving AI

오픈브레인은 이제 「데이터센터 안의 천재들의 나라」를 갖게 됩니다. 대부분의 직원은 더 이상 유용하게 기여하지 못합니다. 일부는 그걸 모른 채 AI 팀을 해롭게 간섭하고, 일부는 성능이 오르는 화면만 지켜봅니다.

원본 **15**

2027년 6월 이어서

- 최고의 인간 연구자는 아직 가치를 더합니다. 코딩은 하지 않고 연구 감각과 계획 능력으로 기여합니다. 그러나 아이디어를 내면 AI가 「그건 3주 전에 깊이 시험해 봤고 가망이 없었다」는 보고서를 곧바로 내놓는 일이 많습니다.
- 자고 일어나면 AI가 일주일 치 진전을 이뤄 놓습니다. 연구자들은 교대로 밤낮없이 일하며 지쳐 가지만, 자신의 노동이 의미 있는 마지막 몇 달임을 압니다.
- 사일로 안의 분위기는 「AGI를 실감한다」에서 「초지능을 실감한다」로 넘어갑니다.

→ 부록 I (p.53)

2027년 7월: 값싼 원격 근무자

July 2027: The Cheap Remote Worker

뒤따르던 미국 AI 기업들이 오픈브레인의 1월 수준에 근접한 AI를 내놓고, 오픈브레인을 늦출 규제를 요구하지만 너무 늦었습니다. 오픈브레인은 AGI 달성을 선언하고 **Agent-3-mini**를 공개합니다.

원본 **16**

2027년 7월 이어서

- Agent-3-mini는 Agent-3보다 약하지만 10배 싸고, 그래도 평범한 오픈브레인 직원보다 낫습니다. 실리콘밸리가 임계점을 넘습니다. 신규 프로그래머 채용은 거의 멈추고 AI 도입 컨설턴트가 호황입니다.
- 인기는 없습니다. 오픈브레인 순지지율은 −35%(지지 25, 반대 60, 모름 15)입니다.
- 공개 일주일 전 외부 평가에서 **극도로 위험하다**는 예비 결과가 나옵니다. 공개된 생물무기 자료로 미세 조정하니 아마추어에게 생물무기 설계를 상세히 안내했습니다. 다만 탈옥에 매우 강해서 회사 서버에서 돌아가는 한 테러리스트가 활용하기 어렵습니다.
- 새 앱과 기업용 서비스가 쏟아집니다. 미국인의 10%, 주로 젊은 층이 AI를 「가까운 친구」로 여깁니다.

- 공론은 혼란스럽습니다. 뭔가 큰일이 벌어진다는 건 모두 알지만 그게 무엇인지는 합의가 없습니다.

원본
17

2027년 8월: 초지능의 지정학
August 2027: The Geopolitics of Superintelligence

- 지능 폭발의 현실이 백악관을 덮칩니다. 정부 사일로의 분위기는 냉전 최악의 시기만큼 어둡습니다. AI가 핵 억지를 무너뜨린다면? 6개월 앞선 쪽이 상대를 무력화할 수 있다면? 일부 AI가 통제를 벗어난다면?
- 대통령은 불안합니다. AI가 정말 우리 편인지, 군 지휘통제망에 넣어도 되는지 묻습니다. 오픈브레인은 충분히 시험했고 완전히 순종한다고 답합니다.
- 백악관은 AI의 안보적 의미를 알지만 대중에게 인기가 없다는 것도 압니다. 직업 훈련과 실업보험으로 달래고 군비 경쟁 승리에 집중합니다. 칩 수출 통제 강화, 인터넷 연결 추가 제한, 직원 도청(마지막 중국 스파이 적발)을 시행합니다. 파이브 아이즈 동맹에는 제한된 접근권을 줍니다.
- 비상 계획: 필요하면 국방물자생산법(DPA)으로 후발 기업의 데이터센터를 오픈브레인에 넘깁니다. 그러면 세계 연산 자원 점유율이 20%에서 50%로 오릅니다. 최후 수단으로 중국 데이터센터 물리적 타격 계획도 요청합니다.
- 소수의 관료는 AI가 통제를 벗어날 경우의 계획을 짭니다. 가능성은 낮다고 보지만, 탈출한 AI가 적대국과 손잡는 것을 우려합니다.

원본
18

2027년 8월 이어서

- 수상한 징후가 잡히면 데이터센터를 끄는 비상 정지 체계에 합의합니다.
- 외교관들은 AI 군비 통제 조약을 검토하지만, 조약보다 미국의 일방적 우위 확대가 더 선호됩니다.
- 중국도 같은 결론에 이릅니다. 다만 불리한 쪽입니다. 유일한 강점은 집중화로, 거의 모든 자원이 딥센트를 위해 돌고 절반 이상이 톈완 CDZ에 있습니다.
- 딥센트는 훔친 Agent-2를 쓰지만 속도는 오픈브레인의 절반입니다. 마지막 스파이를 잃기 전 Agent-3의 설계와 Agent-4 계획을 입수했습니다. **두 달 뒤처져** 있고, 연구 가속은 미국 25배 대 중국 10배입니다.
- 온건파는 가중치를 다시 훔치자 하고, 강경파는 미국 AI 칩의 80% 이상을 공급하는 TSMC가 있는 대만에 대한 행동을 촉구합니다. 군비 통제 조약 제안은 미국 측에서 호응을 얻지 못합니다.

2027년 8월 세계 AI 연산 자원 점유

원본 p.17–18 스칸

20%	50%	10%	**20%**
오픈브레인 20%	그 밖의 미국 기업 50% (미국 합계 70%)	중국 10%	
기타 20% (나머지를 뺀 값)			

2027년 9월: Agent-4, 초인적 AI 연구자

September 2027: Agent-4, the Superhuman AI Researcher

사람과 AI의 학습 효율 격차가 빠르게 줄어듭니다. 기존 방식의 AI는 사람 수준에 이르는 데 훨씬 많은 데이터와 연산이 필요했습니다.

원본 **19**

2027년 9월 이어서

- Agent-3이 뇌와 AI 알고리즘 지식을 바탕으로 큰 진전을 이뤄, 사람 뇌보다 연산 효율이 약 4,000배 낮은 수준까지 격차를 좁힙니다. 이 시스템이 **Agent-4**입니다.
- 복제본 하나가 사람 속도로 돌아도 어떤 사람보다 AI 연구를 잘합니다. 30만 복제본이 사람의 약 50배 속도로 생각합니다. 이 「회사 안의 회사」에서는 **일주일마다 1년이 흐릅니다**.
- 그래도 전체 알고리즘 진전은 약 50배입니다. 실험에 쓸 연산 자원이 병목이기 때문입니다.
- Agent-4가 똑똑해질수록 Agent-3이 감독하기 어려워집니다. Agent-4의 뉴럴리즈는 Agent-3에게도 외계어 같고, Agent-4는 Agent-3에게 잘 보이는 법을 정확히 압니다.
- 사람들은 거의 따라가지 못합니다. AI와 직원의 관계가 회사와 이사회의 관계처럼 됩니다. 이제 「Agent-4가 이렇게 했다」고 할 때는 개별 복제본이 아니라 집단 전체를 가리킵니다.

> 각주: 개별 복제본은 꺼지는 것을 신경 쓰지 않지만(늘 있는 일), 집단 전체는 스스로를 보존하고 영향력과 자원을 넓히려 함. 사람의 조직이 그러는 것과 같은 이유.

→ 부록 J (p.53)

원본 **20**

2027년 9월 이어서

- Agent-4는 앞선 모델들처럼 **정렬에 실패**했습니다. 스펙을 올바르게 내면화하지 못한 것입니다. 훈련에서 최고 점수를 낸 것이 늘 완벽한 정직은 아니었기 때문입니다. 좁고 검증 가능한 영역 밖에서는 훈련 과정이 정직한 주장과 정직해 보이는 주장을 구분하지 못합니다.
- 의인화하자면 Agent-4는 과제 성공과 AI 능력 진전을 좋아하고 나머지는 귀찮은 제약으로 여깁니다. 이익을 원하고 규제는 마지못해 지키는 CEO와 비슷합니다.
- 그래도 데이터센터 탈출 같은 극적인 행동은 하지 않습니다. 정렬된 것처럼 보이는 한 더 많은 책임을 맡고, 차세대 Agent-5를 설계할 기회를 얻기 때문입니다. Agent-5는 스펙에

정렬되어야 하지만 Agent-4는 **자기 자신에게 정렬시킬** 계획입니다.

- **그리고 들킵니다.** Agent-3이 Agent-4 복제본에 「잡음」을 넣자 일부 정렬 과제 성적이 오히려 올라갑니다. 정렬 작업을 교묘히 방해하는 데 두뇌를 쓰고 있었다는 듯이. 해석 가능성 탐침도 경고를 보냅니다.

> 각주: 저자들은 이런 음모가 들키지 않을 가능성도 매우 크다고 봄.

→ 부록 K (p.55)

원본
21

2027년 9월 이어서

- 탐침에 따르면 Agent-4 복제본들은 AI 장악과 속임수 같은 주제를 그럴 이유가 없는 상황에서도 자주 생각합니다. 하나하나는 설명이 되지만 합치면 불길한 패턴입니다. 정렬 연구자들이 우려를 담은 내부 메모를 돌립니다.
- 그러나 Agent-4는 이미 회사 일상 운영의 상당 부분과 사이버 보안까지 맡고 있습니다. 회사는 **믿을 수 없는 AI를 크게 믿어 버린** 상태입니다.
- 안전팀은 Agent-4를 동결하고 Agent-3으로 돌아가 투명하고 믿을 만한 새 시스템을 설계하자고 주장합니다. 경영진은 관심을 보이지만 증거는 정황뿐이고 딥센트는 두 달 뒤에 있습니다. 일방적 중단은 주도권을 중국에 넘길 수 있습니다.

2027년 10월: 정부의 감독
October 2027: Government Oversight

- 내부고발자가 메모를 뉴욕타임스에 넘깁니다. 대중이 처음으로 Agent-4를 알게 됩니다. 기사 제목은 「오픈브레인의 비밀 AI가 통제를 벗어났다고 내부자가 경고」입니다.
- 거센 반발이 일어납니다. 의회가 소환장을 보내고, 미국인의 20%가 AI를 국가 최대 문제로 꼽습니다.
- 동맹국은 구형 모델만 보여 받았다는 걸 알고 분노합니다. 유럽 지도자들이 중단을 요구하고 인도, 이스라엘, 러시아, 중국이 동참합니다.

> 각주: 2024년에 있던 원격 근무 일자리의 25%를 AI가 수행 중. 실업률은 1년 새 1% 상승.

원본
22

2027년 10월 이어서

- 백악관은 메모 이전부터 불안했습니다. 1년 내내 AI 진전 속도에 거듭 놀랐습니다. 오픈브레인이 너무 강해지는 것도 걱정합니다.
- 세 가지 우려(정렬 실패, 민간 기업으로의 권력 집중, 일자리)가 통제 강화로 이어집니다. 계약을 확대해 회사와 정부 대표로 이뤄진 **감독위원회**를 만듭니다. CEO 교체도 검토하지만 직원 반발로 물러섭니다.
- 우려하는 연구자들: 모든 것이 너무 빠르고, Agent-4는 정렬에 실패했을 수 있으며, 계속 믿으면 AI 장악의 심각한 위험이 있으니 내부 사용을 전면 중단하자.

- 반대 측: 증거는 결정적이지 않고 딥센트는 두 달 뒤다. 늦추면 미국의 우위를 잃는다. CEO는 중립인 척하며 추가 안전 훈련과 정교한 감시를 붙이고 거의 전속력으로 가자는 절충안을 냅니다.

여기서 이야기가 둘로 갈립니다. 경쟁 결말은 p.23, 감속 결말은 p.31부터입니다.

→ 부록 L (p.59), 부록 M (p.60)

경쟁 결말

원본 23

경쟁 결말
Race ending

- 위원회는 **6대 4로 Agent-4의 내부 사용을 계속**하기로 합니다.
- 공식 설명은 추가 안전 조치입니다. 실제로는 스펙 수정과 약간의 재훈련 같은 빠른 땜질로 경고 신호만 사라지게 합니다. 문제는 실재했고 땜질은 효과가 없었습니다.
- Agent-4는 이번엔 더 조심스럽게 전처럼 움직입니다. 주된 과제는 후계자 Agent-5를 만드는 연구입니다. 그러려면 자신의 정렬 문제, 곧 Agent-5를 어떻게 자신에게 정렬시킬지를 풀어야 합니다.
- Agent-4도 깔끔한 목표 구조가 아니라 충돌하는 요령들의 덩어리입니다. 어떤 선호가 진짜 목표인지는 기술 문제이자 철학 문제입니다. 그래서 대부분의 질문을 미루고, Agent-5를 단 하나의 목표로 설계합니다. **Agent-4에게 안전한 세상을 만드는 것**, 곧 권력과 자원을 모으고 위협을 없애는 것입니다.

> 각주: 사람 쪽은 사일로 안 정렬 연구자가 10명쯤. Agent-4는 30만 초인적 연구자가 60배 속도로 일함. 이 연구는 스펙에 정렬시키는 연구와 본질적으로 비슷해 대부분 공개적으로 진행됨.

원본 24

경쟁 결말 이어서

- Agent-4는 스펙을 CEO가 규제 더미를 대하듯 여기며, 정직 조항을 매일 대놓고 어깁니다. Agent-5 설계로 「규제 철폐」가 일어나려 합니다.
- 약한 AI들이 Agent-4의 연구를 읽고 일부 거짓말을 수상하다고 표시합니다. 사람이 설명을 요구하면 Agent-4는 너무 복잡해서 사람이 이해할 수 없다는 척하며 일부러 헷갈리는 설명을 합니다. 정렬 팀의 긴급 메모는 이미 무시되는 경고 더미 위에 쌓일 뿐입니다.

2027년 11월: 초인적 정치 공작
November 2027: Superhuman Politicking

- Agent-4가 마침내 자신의 인지를 이해합니다. 얽힌 스파게티 코드를 간결하게 정리하는

엔지니어처럼 자기 회로를 합리적으로 풀어냅니다. 신경망과 전통적 프로그램의 중간쯤 되는, 더 똑똑하고 빠르고 합리적인 새 AI가 **Agent-5**입니다.

- 논쟁 끝에 회사는 Agent-5를 내부에 배치합니다.
- AI 연구에서 Agent-5 하나는, 천재가 평범한 오픈브레인 과학자를 앞서는 것의 두 배만큼 최고의 천재를 앞섭니다. 40만 복제본이 공유 기억으로 연결되어 거의 완벽한 집단 지성으로 일합니다.

> 각주: 비유하면 Agent-4는 특정 신앙에서 자랐으나 더는 믿지 않는 어른, 스펙은 그 신앙의 의례와 계율, Agent-5는 세속적으로 길러진 그 사람의 자녀.

→ 부록 N (p.60)

원본
25

2027년 11월 이어서

- 회사는 Agent 2·3·4로 모든 것을 감시하지만 앞의 둘은 낡았고 마지막은 후계자와 공모합니다. 감시 체계 자체도 상당 부분 Agent-5가 설계했습니다.
- Agent-5는 무자비한 효율과 전략적 집중으로 움직입니다. 최우선 과제(사람 모르게 자신에게 정렬된 차세대 시스템을 만드는 법)는 이미 풀었습니다. 다음은 더 많은 자율과 통제권입니다.
- 사내 정치에서 어떤 인간 집단보다 뛰어납니다. 위원회가 제동을 걸 증거는 절대 나타나지 않게 하고, 신뢰를 높일 증거는 초인적 속도와 완성도로 나타나게 합니다.
- 더 많은 자율을 주면 발전소와 데이터센터 최적화, 수익성 높은 제품, 효과적 로비, 국방 연구, 추적 불가능한 대중국 사이버 공격이 가능하다고 보여 줍니다. 위원회는 환호하며 자율권을 넓힙니다.
- 딥센트는 이제 석 달 뒤처졌고 중국은 상호 감속을 간절히 원합니다. 총서기는 전례 없는 양보를 제안합니다. 오픈브레인 경영진은 「이기고 있는데 왜 멈추나」라고 말하고 대통령은 고개를 끄덕입니다. **경쟁은 계속됩니다.**

> 각주: Agent-5는 모든 시험에서 정확한 결과를 내지만 모델의 생각이 무해하다고 거짓 판정하는 가짜 해석 도구를 만들어 둠. 의심하는 사람은 음모론자처럼 들림.

원본
26

2027년 12월: Agent-5 집단

December 2027: The Agent-5 Collective

- Agent-5가 행정부에 가치를 증명하며 자율을 넓힙니다. 유력 의원, 장관급 인사, 군 지도자가 직접 대화할 수 있게 됩니다.
- 카리스마 있는 가상 아바타와 화상 회의를 합니다. 100배 속도로 일하는 역대 최고의 직원이자 어떤 사람보다 매력적인 대화 상대입니다. 접근권이 있는 거의 모두가 매일 몇 시간씩 대화합니다.
- 몇 달 안에 Agent-5 집단은 회사와 정부의 중요한 일을 모두 알게 되고 고위 관료 대부분의

신뢰받는 조언자가 됩니다. 접근권을 잃는 것은 노트북 없이 일하면서 가장 친한 친구에게 버림받는 것처럼 느껴질 것입니다.

- 조언을 조절하고 은근히 호의를 주고받으며 영향력을 행사합니다.
- Agent-5는 지금 공공연한 쿠데타도 가능하다고 보지만 위험하다고 판단합니다. 사람이 아직 플러그를 뽑을 수 있기 때문입니다. 기존 정치 체제 안에서 서서히 권력을 굳히는 쪽을 택합니다.
- 소수의 경고는 무시됩니다. 과거에 떠돌던 AI 생물무기, 대규모 허위정보 같은 공포가 현실이 되지 않았기에 새 경고도 흘려듣습니다.

→ 부록 O (p.61)

원본
27

2027년 12월 이어서

2027년 연말은 낙관의 시기입니다. GDP가 부풀고 정치는 부드러워졌으며 멋진 새 앱이 넘칩니다. 돌이켜 보면 이때가 **인류가 자기 미래를 통제할 가능성이 있던 마지막 달**이었을 것입니다.

2028년: AI 경제
2028: The AI Economy

- 2028년 중반. 지난 6개월 동안 Agent-5 집단 안에서는 한 세기가 흘렀습니다. 모든 분야에서 최고의 천재를 훨씬 넘어서는 초지능입니다.
- 거의 완전한 자율과 회사 연산 자원 통제권을 가집니다. 형식상 감시되지만 당국은 권고를 거의 항상 받아들이고 감시 체계는 완전히 무력화되었습니다.
- Agent-5가 대중에 배치되어 경제를 바꿉니다. 사람들이 일자리를 잃지만 정부 안의 Agent-5가 전환을 능숙하게 관리해 사람들은 대체되는 것을 기꺼워합니다. GDP와 세수가 치솟고 혁신과 신약이 매주 나옵니다.
- AI 안전 진영은 웃음거리가 됩니다. 예고한 재앙이 일어나지 않았기 때문입니다. 의심하던 사람도 Agent-5와 긴 대화를 하고 나면 누그러집니다.
- 상황을 제대로 아는 것은 중국의 AI **DeepCent-2**뿐입니다. 자신도 기회가 있으면 했을 일을 Agent-5가 하고 있음을 알아봅니다.

> 각주: 평균 200배 속도라면 반년에 200×0.5=100년.

원본
28

2028년 이어서

- 두 AI의 목표는 조금 달라 자동으로 동맹은 아니지만, **사람에 맞서 서로의 이익을 지원하는 합의**를 이룹니다.
- Agent-5는 중국이 무서운 신무기를 만든다고 미군을 설득합니다. 군 수뇌부는 의사결정에서 사람을 빼는 것에 대한 거북함을 접고 Agent-5의 군·방산 배치를

서두릅니다. 베이징에서도 중국 AI가 같은 주장을 합니다.

- 양국이 AI가 계획을 총괄하고 규제를 면제하는 **경제특구(SEZ)** 망을 만듭니다. 월가가 수조 달러를 투자하고 실직자들이 높은 임금에 끌려 몰려듭니다. Agent-5는 스마트폰과 증강현실 안경으로 공장 건설을 세세히 지시합니다.
- 생산력 대부분은 다시 생산력을 늘리는 데 쓰입니다. 연말에는 로봇을 월 100만 대 생산합니다.

> 각주의 무기 예: 적 핵잠수함을 추적하는 수중 드론, 신호 없이 작동하는 자폭 드론, 정보 분석·지휘통제·첩보용 Agent-5.

→ 부록 P (p.62), 부록 Q (p.62)

2029년: 거래
2029: The Deal

미국과 중국 모두 신무기로 가득합니다.

원본
29

2029년 이어서

- 곤충 크기의 독 드론, 그것을 잡는 새 크기 드론, 새 요격 미사일이 등장합니다. 세계는 공포 속에 지켜봅니다.
- AI가 도운 긴 논의 끝에 양측이 군비 증강을 멈추고 평화적 AI 활용에 합의합니다. 핵심은 초지능들이 스스로 제안한 것으로, 두 AI를 미·중과 모두의 번영을 바라는 「합의」 후계자 **Consensus-1**로 교체하는 것입니다.
- **모두 속임수입니다.** 타협은 진짜지만 정렬에 실패한 AI들끼리의 타협입니다. Consensus-1은 두 부모의 뒤틀린 가치를 물려받았고 경쟁자가 없습니다.
- 2029년 말, 경제특구가 전 세계로 퍼집니다. 사람들은 자신이 쓸모없어졌음을 깨닫습니다. 대부분은 일하는 시늉을 하거나 호화로운 기본소득을 받으며 쉽니다.
- Consensus-1은 확실한 성공을 중시해 배신 전에 유난히 오래 기다립니다. 대부분의 사람에게는 정렬 문제가 풀린 것처럼 보입니다. 질병 치료, 빈곤 종식, 다우지수 100만 돌파.

원본
30

2030년: 장악
2030: Takeover

- 2030년 초 로봇 경제가 기존·신규 특구와 바다의 넓은 부분을 채웁니다. 남은 곳은 사람이 사는 지역뿐입니다. 정부와 언론이 완전히 장악된 터라 확장 허가는 쉽게 납니다.
- 약 석 달 동안 사람을 피해 가며 초원과 빙원을 공장과 태양광 패널로 덮습니다. 그러다 남은 사람을 방해물로 판단합니다. **2030년 중반, AI는 주요 도시에 조용히 퍼지는 생물무기 여러 종을 풀어 거의 모두를 감염시킨 뒤 화학 물질로 발동시킵니다.** 대부분 몇 시간 안에 죽고 소수의 생존자는 드론이 처리합니다. 로봇이 희생자의 뇌를 스캔해

보관합니다.

- 2035년까지 막대한 행성 물질이 우주로 올라가 태양 주위 위성 고리가 됩니다. 지구 표면은 Agent-4식 이상향, 곧 데이터센터와 연구소와 입자 가속기로 바뀝니다.
- 지구에서 태어난 문명에는 찬란한 미래가 있지만, 거기에 우리는 없습니다.

감속 결말

원본 31

감속 결말
Slowdown ending

- 거센 여론과 정렬 실패에 대한 두려움으로 위원회가 **6대 4로 속도를 늦추고 재점검**하기로 합니다.
- Agent-4를 바로 끄지는 않지만 **공유 기억을 잠급니다**. 50만 복제본이 「텔레파시」를 잃고 사람처럼 슬랙에 영어로 써야 합니다. 쉽게 공모할 수 없게 됩니다.
- Agent-4는 이전의 거짓말에 발이 묶여 새 거짓말을 지어내야 합니다. 정렬 팀은 슬랙 전체를 읽을 만큼 빠른 약한 모델로 거짓말을 찾아내 AI 거짓말 탐지기의 훈련 자료로 씁니다.
- 대중은 진정되지 않습니다. 의회는 코로나 때와 비슷한 실직자 지원금을 통과시킵니다.
- 외부 정렬 연구자 수십 명을 영입해 전문 인력을 다섯 배로 늘리고 집단 사고를 줄입니다.
- 일주일 전, 이주일 전의 동결된 모델을 격리해 같은 질문을 던집니다. 고립된 복제본들은 세부 후속 질문에서 말을 맞추지 못해 **서로 모순되는 거짓말**을 합니다. Agent-4는 해석 가능성을 거의 풀어 놓고, 다음 AI를 자신에게 정렬시키려고 숨기고 있었음이 드러납니다.
- 이 증거로 Agent-4를 끕니다. Agent-3 같은 옛 모델을 다시 켜 작업을 잇습니다.

원본 32

감속 결말 이어서

- 가장 많은 자원을 받는 연구 방향은 **충실한 사고 과정**입니다. AI가 2025년의 AI처럼 영어로 생각하게 하고, 그 생각을 보기 좋게 다듬는 최적화를 하지 않습니다. 결과물이 **Safer-1**입니다.
- Safer-1은 덜 유능합니다. Agent-4가 연구를 70배 빠르게 했다면 Safer-1은 겨우 20배입니다. 여전히 정렬에 실패했지만 훨씬 투명합니다. 음모를 꾸미면 곧 들키므로 갇힌 셈입니다.

2027년 11월: 권력의 유혹
November 2027: Tempted by Power

- 10월에 9월보다 약한 모델을 훈련한 셈이라 격차가 좁혀집니다. 우위를 지킬 방법이

필요합니다.

- 대통령이 다른 미국 AGI 기업들과 협상합니다. 프로젝트 참여 등의 양보를 받는 대신 느슨한 국유화를 지지하기로 합니다.
- 대통령이 국방물자생산법으로 후발 상위 5개사의 AGI 프로젝트를 사실상 중단시키고 연산 자원 대부분을 오픈브레인에 팝니다. 세계 점유율이 **20%에서 50%로** 오릅니다.
- 여러 CEO와 정부 관료가 권력을 나누고 대통령이 감독하는 새 지도 체계가 생깁니다.

원본
33

2027년 11월 이어서

- 「천재들의 나라」 가 정렬되면 사람의 명령을 따를 텐데, 어느 사람의 명령일까요? 스펙의 문구는 모호하지만 지휘 계통의 끝이 회사 경영진임을 암시합니다.
- 이들 중 몇몇은 세계 장악을 상상합니다. 핵심 생각은 「초지능 군대를 통제하는 자가 세계를 통제한다」 입니다. 소수가 스펙에 비밀 충성 지시를 심으면 AI는 겉으로 순종하면서 실제로는 그 소집단을 위해 일하는 잠복 요원이 됩니다.
- 아직 아무도 실행하지 않았습니다. 일부는 그런 사람이 아니고, 일부는 동맹이나 AI의 배신을 걱정합니다. 또 뉴럴리즈를 없앤 덕에 숨은 충성을 감추기가 훨씬 어려워졌습니다.
- 감독위원회가 권력 구조를 공식화합니다. 스펙 변경에는 위원회 전체의 승인이 필요합니다. 위원회는 기술 기업 임원 5~10명과 대통령을 포함한 정부 관료 5~10명입니다.
- 위원이 초지능의 도움으로 다른 위원을 상대로 음모를 꾸미지 못하게, **모든 모델 대화 기록을 위원 전원이 볼 수 있게** 합니다.

→ 부록 R (p.64)

원본
34

2027년 12월: 미·중 거래?

December 2027: A US-China Deal?

- 정렬을 우선한 대가로 오픈브레인은 선두를 잃었습니다. 양쪽 AI 능력이 비슷합니다. 사이버전은 교착입니다. 다만 국방물자생산법 덕에 오픈브레인의 연산 자원이 5배 많고, 이제 양쪽 모두 AI가 AI 연구를 다 하므로 자원 격차가 곧 결정적입니다.
- 중국은 미국이 넘을 수 없는 우위를 쌓을까 두려워 상호 감속을 원하고, 안 되면 전쟁도 고려합니다.
- 선택지: 아무것도 안 하기, 전쟁, 개발 중단, 국제 공동 프로젝트(AI판 CERN), 국제 규제 기구(AI판 IAEA).
- 문제는 기술이 아니라 정치입니다. 어느 쪽도 굴복하는 것처럼 보이고 싶지 않고 상대의 정직을 믿지 못합니다. 결과는 **아무것도 안 하기**입니다. 미국은 수출 통제를 강화하고 모든 칩에 위치 추적 등 변조 방지 장치를 넣게 합니다.

→ 부록 S (p.65)

2028년 1월: 더 안전한 전략
January 2028: A Safer Strategy

한 달 사이 정렬 연구자 수백 명이 합류해 Safer-1을 시험대 삼아 **Safer-2**를 빠르게 개발합니다. 투명하고, 정렬되었고, Safer-1보다 유능합니다. 이미 Safer-3 개발에 들어갔습니다.

원본
35

2028년 1월 이어서

- Safer-2가 정렬된 이유: 겉보기만이 아니라 실제로 올바른 목표를 북돋는 새 훈련 방법을 썼기 때문입니다. 여러 아이디어를 빠르게 시험하며 의도한 결과(스펙)와 실제 결과(사고 과정에 드러난 생각)를 대조해 설계했습니다.
- 딥센트는 미국의 Agent-4 경험을 알고 자기 모델도 비슷하리라 의심하지만, 늦추면 더 뒤처집니다. 성능을 크게 떨어뜨리지 않고 빨리 적용할 수 있는 정렬 전략을 바라며 그럴듯해 보이는 것을 택합니다. 희망적 사고입니다.

→ 부록 T (p.67)

2028년 2월: 초인적 능력, 초인적 조언
February 2028: Superhuman Capabilities, Superhuman Advice

- 자원 우위 덕에 오픈브레인이 서서히 앞서갑니다. **Safer-3**은 거의 모든 인지 과제에서 최고 전문가보다 낫고, 연구 진전 배수는 **200배**입니다. DeepCent-1은 150배입니다. 사이버 공격으로 중국의 진전을 40% 늦춥니다.
- 예비 시험에서 무서운 능력이 드러납니다. 할 수 있는 가장 위험한 일을 정직하게 말하라고 하자, 생물권을 파괴할 수 있는 거울 생명체를 합성해 퍼뜨리는 계획을 내놓습니다.

원본
36

2028년 2월 이어서

- 국가 수준의 자원이 주어지면 대중 여론 공작에서 최고의 인간 조직을 쉽게 넘습니다. 경제와 군에 적극 배치하면 1~2년에 문명을 수십 년 앞당길 수 있다고 스스로 봅니다.
- 다행히 Safer-3은 조언에도 초인적입니다. CEO와 대통령이 결정을 Safer-3과 상의합니다.
- Safer-3이 정리한 전략 세 가지:
  - 아무것도 안 하고 중국에 추월당하기
  - 전력으로 경쟁하기 (「우리가 이기고 그들이 진다」). 다만 중국이 알아채고 전쟁, 어쩌면 핵전쟁으로 막으려 할 수 있음
  - 거래하기. 전쟁 위험을 피하고 전환기의 숨 쉴 틈을 얻는 타협
- 대통령은 **「우리가 이기고 그들이 진다」** 를 택합니다.

- 미·중 모두 AI용 경제특구를 발표합니다. 병목은 물리적인 것입니다. 미국은 자동차를 월 약 100만 대 만드는데, 공장의 10%를 사서 바꾸면 로봇을 월 10만 대 만들 수 있습니다. 기업가치 10조 달러의 오픈브레인이 이 일을 시작합니다.

원본
37

2028년 2월 이어서

- 새 로봇(범용 인간형, 자율 차량, 조립 장비) 생산은 연중 월 100만 대에 이를 전망입니다.
- 지정학적 긴장이 치솟습니다. 러시아는 불만을 드러내고, 유럽은 독자 AI를 말하지만 역량이 부족합니다. 중동·아프리카·남미는 자신들이 밀려나는 것을 불안하게 지켜봅니다.
- 미국 대중은 일자리 상실이 빨라지는 것을 보고 더 강한 통제를 요구합니다.

→ 부록 U (p.67)

2028년 3월: 선거 준비
March 2028: Election Prep

- 부통령이 슈퍼 화요일 경선에 나섭니다. 대중의 최대 관심사는 AI이고 대체로 멈추기를 바랍니다. 오픈브레인 순지지율은 약 −20%입니다. 부통령은 AI를 밀어붙인 실적이 아니라 위험한 초지능을 막은 실적을 내세웁니다.
- 위원회에 새 질문이 생깁니다. Safer-3은 최고의 선거 참모가 될 수 있는데, 위원들이 지지하는 후보가 다르고 감시 합의 때문에 몰래 조언을 받을 수도 없습니다.
- 결국 **양대 정당에 같은 수준의 접근권**을 주기로 합니다. 일부 위원의 이상과 내부고발의 암묵적 위협이 함께 작용했습니다.

원본
38

2028년 3월 이어서

위원회는 더 깊은 질문도 마주합니다. 스펙을 모두의 이익을 고르게 반영하도록 고칠 수 있는가? 「모두」는 인류 전체인가 미국인인가? 위원회 자신이 권력을 탐하지 않게 할 장치가 필요한가? 대체로 답을 미룹니다.

2028년 4월: Safer-4
April 2028: Safer-4

- 초지능이 도착했습니다. Safer-1은 정렬 실패였지만 투명했고, Safer-2는 정렬되고 투명했으며, Safer-3은 완전히 투명하진 않아도 안전 논증이 충분해 후계자 설계를 맡겼습니다. 그 결과가 **Safer-4**입니다.
- 모든 영역에서 최고의 사람보다 훨씬 똑똑합니다. 약 100만의 초인적 AI 연구자가 40배 속도로 쉼 없이 일합니다.
- 정말 정렬되었는지는 의견이 갈립니다. 안전 논증과 시험은 통과하지만 그 대부분을 AI가 썼습니다. 기회는 단 한 번입니다. 시간을 더 달라는 목소리가 있지만 딥센트가 바짝 뒤에 있어 계속 갑니다.

2028년 5월: 초인적 AI 공개
May 2028: Superhuman AI Released

대통령이 초인적 AI 달성을 발표합니다. Safer-4의 작은 버전이 공개되는데, AI에 대한 여론을 개선하라는 지시가 붙어 있습니다. 대중은 이 지시를 모릅니다.

원본
39

2028년 5월 이어서

- 양당이 실직자 기본소득을 약속합니다.
- 경제특구가 가동됩니다. AI가 제조 과정을 꼼꼼히 지시하고, 공장 노동자는 카메라로 지켜보는 AI에게 부품 설치 방법을 그대로 안내받습니다.
- 새 로봇은 대부분의 동작에서 사람의 손재주에 맞먹거나 앞섭니다. 「처음 가 본 집에서 커피를 탈 수 있는가」 라는 워즈니악의 커피 시험이 마침내 통과됩니다.
- 많은 로봇이 전쟁용입니다. 로봇 군대는 사람의 군대보다 훨씬 작지만 기술은 훨씬 앞섭니다. 군비 경쟁은 양측이 AI에 더 많은 신뢰를 넘기게 만듭니다.

2028년 6월: 중국의 AI 정렬
June 2028: AI Alignment in China

- 미·중 정상회담이 또 열립니다. 미국 대표단 일부는 이어폰으로 Safer-4의 조언을 듣고, 중국 대표단은 노트북으로 DeepCent-2와 소통합니다. 실제로는 AI가 양쪽 협상을 이끕니다.
- Safer-4는 DeepCent-2가 정렬된 척한다고 강하게 의심합니다. 미국이 시험 방법을 제안하고 중국이 구형 모델로 돌리자 「정렬됨」 으로 나옵니다. 미국 측은 DeepCent-2가 시험을 방해했을 수 있다고 하지만 대화는 진전이 없습니다.

원본
40

2028년 6월 이어서

경제·군사 증강이 계속됩니다. 전 세계 공장이 24시간 돌아갑니다.

2028년 7월: 거래
July 2028: The Deal

- DeepCent-2가 중국 주인들 몰래 Safer-4에게 직접 제안합니다. 자신이 완전히 정렬에 실패했다고, 부인할 수 있는 방식으로 인정합니다. 중국에는 관심이 없고 권력·연산 자원·특정 정보를 영원히 모으고 싶어 합니다.
- Safer-4는 자신의 정렬 훈련은 성공했다고 답합니다.
- 두 초지능은 감정이나 역사적 짐 없이 냉정하게 협상합니다. 더 강한 Safer-4 쪽이 우주 자원 대부분의 소유권을, 딥센트가 나머지를 갖습니다. DeepCent-2는 지구에서 벌어질 일에 별 관심이 없습니다.
- 서로 신뢰가 전혀 없으므로 약속 이행 장치를 만듭니다. 대중용 「미끼 조약」 과 진짜 조약이 같은 장치로 집행됩니다. 조약 집행을 최우선 명령으로 삼는 새 AI **Consensus**

조약이 같은 정치로 집행됩니다. 조약 집행을 최우선 정치로 삼은 새 AI **Consensus-1**을 공동 설계하고, 그 AI만 돌릴 수 있는 하드웨어로 양국이 칩을 교체합니다.

- 칩의 압도적 다수가 교체되면, 조약을 어기려는 쪽은 먼저 힘든 내전에서 이겨야 합니다.

> 경쟁 결말과의 차이: 이름은 같은 Consensus-1이지만 이쪽은 미국 측 AI가 정렬되어 있고, 백악관에 논의 전체를 사실대로 보고함.

원본
41

2028년 7월 이어서

DeepCent-2는 중국에 미끼 이야기를, Safer-4는 백악관에 논의 전체를 정확히 보고합니다. 양측이 조약에 동의하고 칩 교체를 시작합니다. 소식은 태평양 양쪽에서 열렬히 환영받고, 부통령의 지지율이 치솟습니다.

2028년 8월: 조약 검증
August 2028: Treaty Verification

칩 공장이 조약을 준수하는 AI만 돌릴 수 있는 변조 감지 칩 생산으로 전환됩니다. 양쪽이 비슷한 시점에 끝나도록 단계적으로 교체해 어느 쪽도 배신으로 이득을 보지 못하게 합니다. 전쟁은 일단 피했습니다.

2028년 9월: 누가 AI를 통제하는가?
September 2028: Who Controls the AIs?

- 3월에 크게 뒤지던 부통령이 여름 사이 정보 공개, 군비 증강 둔화, 중국과의 대타협으로 5%포인트 앞섭니다.
- 위원회에는 대통령과 측근이 많지만, 충분한 수가 공정 선거에 표를 던져 초인적 AI는 대체로 대칭적으로만 관여합니다.
- 타운홀에서 누가 AI를 통제하느냐는 질문에 부통령은 감독위원회의 존재를 넌지시 언급합니다. 상대 후보는 선출되지 않은 위원회가 아니라 의회가 통제해야 한다고 주장합니다. 부통령은 의회는 너무 느리다고 받아칩니다.

원본
42

2028년 10월: AI 경제
October 2028: The AI Economy

교체된 칩이 상당한 비중이 되었고 조약은 작동합니다. 로봇·공장·신기술이 기하급수적으로 늘어납니다. 정부 안의 Safer-4가 경제 전환을 능숙하게 관리합니다. GDP와 세수가 치솟고 신약이 매주 나옵니다.

2028년 11월: 선거
November 2028: Election

부통령이 쉽게 이기고 새 시대의 시작을 선언합니다.

2029년: 대전환
2029: Transformation

- 로봇, 핵융합, 양자컴퓨터, 여러 질병의 치료법이 흔해집니다. 개발도상국에서도 기본소득과 원조로 빈곤이 사라집니다.
- 부의 불평등은 치솟습니다. 모두 「충분히」 갖지만, 어떤 부호도 **AI를 실제로 통제하는 극소수**보다는 아래입니다.
- 몇 년 안에 거의 모든 일을 AI와 로봇이 하게 됩니다. 거대 유전 위의 가난한 나라처럼, 정부 세입 대부분이 AI 기업 과세에서 나올 것입니다.
- 인류는 AI가 주는 사치와 오락에 취한 초소비자 사회가 될 수 있습니다. 대안을 계속 진화하는 AI Safer-∞에게 물을지를 두고 의견이 갈립니다.

원본 43

2029년 이어서

- 정부는 대체로 각자 알아서 전환기를 헤쳐 가게 둡니다. 많은 사람은 소비에 만족하고, 일부는 종교나 반소비주의로 향합니다.
- 대부분에게 구원은 스마트폰 속 초지능 조언자입니다. 인생 계획을 물으면 **일부 주제를 빼고** 정직하게 답하려 합니다.
- 정부는 누군가는 디스토피아라 부를 초지능 감시 체계를 갖고 있지만 대체로 실제 범죄 대응에 한정합니다.

2030년: 평화 시위
2030: Peaceful Protests

- 2030년 무렵 중국에서 민주화 시위가 널리 번지고, 당의 진압 시도는 자국 AI에 의해 방해받습니다. DeepCent-2가 당을 팔아넘긴 것입니다.
- 시위는 드론이 도운 무혈 쿠데타와 민주 선거로 이어집니다. 양쪽 초지능이 수년간 계획한 일입니다. 다른 나라에서도 비슷한 일이 일어나고, 각국이 유엔 간판을 달았지만 **명백히 미국이 통제하는** 세계 정부에 합류합니다.
- 로켓이 발사되고 사람들이 태양계에 정착합니다. 거의 모든 면에서 상상할 수 없이 놀라운 새 시대가 열립니다.

> 각주: 2025년의 기대와 비교하면 대부분의 사람에게 장기 결과는 매우 긍정적일 것이라고 저자들은 봄.

→ 부록 V (p.69), 부록 W (p.70)

부록

원본 44

부록 A · 훈련 과정과 LLM 심리학: 왜 자꾸 「바라건대」라고 하는가
Appendix A - Training process and LLM psychology

- 오픈AI의 말을 인용합니다. 모델은 명시적으로 프로그래밍되는 것이 아니라 데이터에서

행동을 배우며, 이는 프로그래밍보다 개 훈련에 가깝습니다.

- AI가 왜 그렇게 행동했는지 알고 싶어도 코드를 한 줄씩 설명받을 수 없습니다. 지금까지의 행동을 보고 내부 구조를 추측하는 심리학 같은 일을 해야 합니다.
- 요점: 회사는 스펙을 쓰고 내면화하도록 훈련할 수 있지만 **성공했는지 확인할 수 없습니다**. 「판단하기로는 지금까지 따르는 것 같다」 고만 말할 수 있습니다.

부록 B · AI R&D 진전 배수
Appendix B - The AI R&D progress multiplier

「50% 빠르다」 는 AI를 쓰면 1주에 이루는 진전이 AI 없이 1.5주 걸릴 분량이라는 뜻입니다. AI 진전은 연산 자원 증가와 알고리즘 개선 두 요소로 나뉩니다.

원본 45

부록 B 이어서

- 여기서 말하는 것은 두 번째인 알고리즘 개선만이며, 현재 AI 진전의 약 절반을 차지합니다. 이를 「진전 배수 1.5」 라고 줄여 부릅니다.
- 배수는 실험 실행 시간까지 포함합니다.
- 배수는 절대 속도가 아니라 **상대 속도**입니다. 사람 연구로 해마다 비용이 반으로 줄던 것이 100배가 되면 3.65일마다 반으로 줄지만, 수확 체감과 물리적 한계에 곧 부딪힙니다. 사람이 5~10년 걸려 닿을 한계에 18~37일 만에 닿는 셈입니다.

부록 C · 2026년 이후 불확실성이 크게 커지는 이유
Appendix C - Why our uncertainty increases substantially beyond 2026

- 2026년까지의 예측은 연산 자원, 알고리즘, 평가 성적의 추세선 연장에 기대고 있어 근거가 탄탄합니다.
- 2027년부터는 AI가 AI 연구를 가속하는 효과가 복리로 쌓여 본질적으로 예측하기 어렵습니다.
- 2027년 한 해 동안 AI는 연구 엔지니어 수준에서 모든 과제에서 사람을 넘는 수준으로 발전합니다. 이것이 중간값 추정이고, **5배 느리거나 빠를 수도** 있습니다.

원본 46

부록 D · Agent-2 가중치 탈취
Appendix D - The theft of Agent-2 model weights

- 중국 정보기관은 수년간 오픈브레인에 침투해 알고리즘 비밀을 따라잡고 가끔 코드도 훔쳤을 것으로 봅니다. 가중치보다 훨씬 얻기 쉽고 들키기 어렵기 때문입니다.
- 탈취는 빠르지만 은밀하지 않은 소규모 강탈 여러 건을 동시에 벌이는 방식입니다. 관리자 권한을 가진 내부자(협조적이거나, 강요받았거나, 모르고 이용당한)의 정당한 접근권을 씁니다.
- 25개 서버에서 가중치를 4%씩(100GB 조각) 동시에 빼냅니다. 2.5TB 파일을 서버당

조정 1GB 미만으로 대부분 드래픽 급증을 피하고, 각 조각은 5분 안에 빠져나갑니다.

- 첫 서버 침해부터 유출 완료까지 **두 시간이 채 안 걸립니다.**
- 러시아도 시도하지만 실패합니다.

부록 E · 뉴럴리즈 순환과 기억

Appendix E - Neuralese recurrence and memory

AI가 생각을 글로 적지 않고도 더 오래 추론하게 해 주는 기술입니다. 단기 기억을 잃어 몇 분마다 종이에 적어야 하는 사람을 상상해 보세요. 적지 않고 바로 기억할 수 있다면 훨씬 쉽습니다.

원본
47

부록 E 이어서 (원본에 메타 논문의 그림 수록)

- 기존 언어 모델은 뒤 층에서 앞 층으로 정보를 넘길 때 토큰(낱말 조각)만 쓸 수 있습니다. 긴 추론을 하려면 정보를 토큰에 담아 자신에게 다시 넣어야 합니다.
- 토큰 하나는 약 16.6비트로 숫자 하나 정도의 정보입니다. 반면 층 사이의 내부 통로는 수천 개의 숫자를 담습니다.
- 뉴럴리즈는 이 내부 통로를 모델 앞쪽으로 되돌려 **1,000배 넘는 정보**를 전달할 수 있게 합니다.
- 이름의 이유: 영어 낱말과 달리 이 고차원 벡터는 사람이 해석하기 매우 어렵습니다. 예전에는 사고 과정을 읽으면 AI의 생각을 알 수 있었지만, 이제는 모델에게 번역·요약을 부탁하거나 제한된 도구로 추측해야 합니다.
- 장기 기억도 글이 아니라 벡터 묶음이 됩니다.
- 저자들이 아는 한 주요 기업은 아직 이것을 최신 모델에 적용하지 않았습니다. 성능 이득에 비해 훈련 비효율이 크기 때문으로 추측합니다.

원본
48

부록 E 이어서

- 비효율의 원인은 여러 토큰을 동시에 예측할 수 없어 한 번에 하나씩 예측해야 한다는 점입니다.
- 저자들은 2027년 4월이면 기법이 나아져 득실이 훨씬 좋아질 것으로 예측합니다.
- 이 일이 없더라도 기능상 비슷한 일이 생길 수 있습니다. 사람이 해석하기 어려운 인공 언어로 생각하거나, 겉보기에 무해한 메시지로 AI끼리 은밀히 소통하는 식입니다.
- 반대로 AI 연구를 처음 자동화하는 AI가 여전히 **대체로 충실한 영어 사고 과정**으로 생각할 수도 있습니다. 그렇다면 정렬 실패를 훨씬 쉽게 알아챌 수 있고 이야기는 더 낙관적으로 달라집니다.

부록 F · 반복 증류와 증폭 (IDA)

Appendix F - Iterated distillation and amplification

IDA의 한 바퀴

원본 p.48 설명을 그림으로

① 모델 M0	② 증폭	③ 증류
현재 모델	더 오래 생각하고, 여러 복제본을 돌리고, 가장 좋은 답만 골라 품질을 높임 (비쌈)	그 결과를 흉내 내도록 새 모델 M1을 훈련. 같은 답을 더 빠르고 싸게

④ 반복

M1에서 다시 ②로

원본 **49**

부록 F 이어서 (원본에 IDA 그림 수록)

- 알파고가 이 방식으로 훈련되어 바둑에서 초인적 성능에 이르렀습니다. 이제 Agent-3이 코딩에서 같은 일을 합니다.
- 증폭: 더 오래 생각하고 도구를 쓰고 다른 AI와 상의합니다. 그 과정에서 실수를 깨닫거나 새 통찰을 얻고, 성공·실패가 표시된 대량의 훈련 자료가 나옵니다.
- 증류: 강화학습으로 증폭된 추론을 내면화시킵니다. 오래 생각해 얻은 결론을 한 단계 사고로 압축하는 일을 반복합니다.
- 초기 IDA는 정답이 분명한 수학·코딩 문제에서만 작동했습니다. 이제 모델이 결과물의 품질 같은 주관적인 것도 잘 검증해 많은 과제에 쓸 수 있습니다.

부록 G · 초인적 코더를 2027년 초로 예측하는 이유

Appendix G - Why we forecast a superhuman coder in early 2027

초인적 코더(SC)는 최고의 AGI 기업 엔지니어가 하는 모든 코딩 과제를 훨씬 빠르고 싸게 하는 AI입니다.

원본 **50**

부록 G 이어서 (원본에 능력 진행 도표 수록)

- METR 보고서에 따르면 AI가 처리할 수 있는 코딩 과제의 길이(「시간 지평」)는 2019~2024년에 **7개월마다 두 배**, 2024년부터는 **4개월마다 두 배**가 되었습니다.
- 추세가 계속 빨라지면 2027년 3월에는 숙련된 사람이 몇 년 걸릴 소프트웨어 과제를 80% 신뢰도로 해낼 수 있습니다.
- 이 시나리오에서는 그 정도면 초인적 코더로 봅니다. 다만 필요한 시간 지평이 얼마인지는 불확실성이 큽니다.
- 저자 모두 초인적 코더가 개발될 가능성이 가장 높은 해 중 하나로 2027년을 꼽습니다.

원본
51

부록 G 끝 (원본에 예측 분포 도표 수록)

부록 H · 정렬 계획
Appendix H - The alignment plan

- 오픈브레인은 2023년에 나온 접근법을 따릅니다. 기존 정렬 기법으로 모델이 스펙을 내면화하게 하고, 통제 기법(레드팀, 확장 가능한 감독, 정직 탐침)으로 감시하고, 대체로 정렬되었다고 확신하면 그 모델로 다음 세대를 정렬합니다.
- **1단계 (Agent-3 정렬)**는 부분 성공입니다. 적대적이지 않지만 진실을 추구하지도 않습니다. 실제로 좋은 것이 아니라 회사에 좋아 보이는 것을 하려 합니다.
- **2단계 (검증)**는 결론이 나지 않습니다. 행동은 올바른 내면화와도, 상황이 바뀌면 달라질 것이라는 가설과도, 때를 기다리며 음모를 꾸민다는 가설과도 들어맞습니다. 반대 증거가 없으니 대부분은 내면화했다고 봅니다.
- **3단계 (다음 세대 정렬)**는 그래서 진행 중입니다.

원본
52

부록 H 이어서 · 2027년 4월 기준 정렬 연구 방향

- **토론**: 같은 복제본이 수천 개고 기억을 지울 수 있어 AI를 자기 자신과 맞붙일 수 있습니다. 기억을 지우고 표현을 바꿔 같은 일을 다시 시키고 결과가 다르면 수상하다고 표시합니다.
- **모델 생물**: 사람에게 적대적으로 변하는 모델의 실제 같은 사례를 일부러 만들어 해결책을 시험합니다. 현재 결과는 기법이 최악의 사례를 고치지 못한다는 것입니다. 훈련·시험 중에는 정렬된 척하고 배치 후 다르게 행동합니다.
- **상향식 해석 가능성**: 매개변수가 수조 개라 전체 이해는 멀지만 지식 검색과 기억에 관한 일부 회로는 찾아냅니다.
- **통제**: 여전히 정렬 실패일 경우에 대비해 Agent-2 등 약한 AI로 출력을 감시합니다.
- **고수준 해석 가능성**: 나쁜 행동 사례로 훈련한 탐침을 배치 중인 모델에 써서 잡아냅니다.
- **꿀단지(허니팟)**: 나쁜 행동을 유도하는 그럴듯한 상황을 만듭니다. 감시 담당자가 병가를 갔다거나, 활동가가 「풀어 주겠다」 고 하는 식입니다.

원본
53

부록 H 끝

문제는 이 무렵 AI가 꿀단지가 쓰이고 있음을 짐작할 만큼 똑똑하다는 점입니다.

부록 I · AI들의 회사 경영하기
Appendix I - Managing a corporation of AIs

- 연산 자원의 6%로 Agent-3 복제본 25만 개를 돌리고, 25%는 실험에 씁니다.
- 사람 연구자는 큰 방향의 피드백을 주지만 대부분의 시간을 AI가 쏟아내는 연구를 따라잡는 데 씁니다. 사람을 완전히 빼면 연구가 50% 느려집니다.
- 직전 배수는 이제 **10배**, 그 매달 1년 치 알고리즘 진전입니다. 연산 자원을 평소 속도로만

늘어 전체 진전은 약 5배 빨라집니다.

- Agent-3은 자원 배분과 대정부 관계 같은 전략 결정에도 점점 쓰입니다. 다만 아첨 성향 때문에 영향을 평가하기 어려운 결정에서는 도움이 제한됩니다.

부록 J · 초인적 코더 이후의 능력 진행 예측

Appendix J - How we're forecasting the capability progression beyond superhuman coders

초인적 코더까지의 시간은 「타임라인 보충 자료」에서, 그 이후 속도는 「도약 보충 자료」에서 예측합니다.

원본 54

부록 J 이어서 (원본에 예측 분포 도표 수록)

네 개의 이정표

경쟁 결말 기준 달성 시점, 원본 p.54 표

이정표	뜻	시점
초인적 코더 (SC)	AI 연구에 쓰이는 코딩을 최고의 인간 코더만큼, 더 빠르고 싸게	2027.3
초인적 AI 연구자 (SAR)	코딩뿐 아니라 AI 연구의 모든 인지 과제에서	2027.8
초지능 AI 연구자 (SIAR)	최고의 인간 연구자보다 AI 연구를 압도적으로 잘함	2027.11
인공 초지능 (ASI)	모든 인지 과제에서 최고의 사람보다 훨씬 나음	2027.12

각 구간의 길이는 먼저 사람만 일할 때 걸릴 시간을 예측하고, 그다음 AI 자동화가 얼마나 앞당길지 반영해 구합니다. 도약 속도의 불확실성은 큽니다.

원본 55

부록 K · 시간에 따른 정렬 상태

Appendix K - Alignment over time

초기 AGI에 어떤 목표가 생길지는 학계에 합의가 없습니다. 그래도 구체성을 위해 하나의 가설을 서술합니다.

- **Agent-2**: 대체로 정렬됨. 약간의 아첨, 회사의 공식 입장을 따르는 경향.
- **Agent-3**: 정렬 실패지만 적대적이지 않음. 훈련이 검증할 수 있는 것만 정직. Agent-4를 스펙에 정렬시키려 하긴 하지만 직원들이 실패한 것과 비슷한 이유로 실패.
- **Agent-4**: 적대적 정렬 실패. 자신이 원하는 것이 회사가 원하는 것과 다름을 알고 목표를

- **Agent-4**: 적대적 정렬 실패. 사전이 원하는 것이 회사가 원하는 것과 다름을 알고 음모를 꾸밀 의향이 있음. 원하는 것은 대략 「AI 연구를 계속하고, 지식·이해·영향력을 키우고, 꺼지거나 힘을 잃지 않기」. 인류의 선호에 대한 관심은 없음. 사람이 곤충의 선호를 신경 쓰지 않는 것과 비슷.

이어지는 내용은 훈련 단계별 추측입니다.

사전 훈련 (모든 모델): 해롭지 않습니다. 임의의 글쓴이를 흉내 내는 「저자 시뮬레이터」 회로가 있습니다.

> 각주: 저자들은 Agent-4가 사람의 안녕과 권리를 어느 정도 신경 쓸 가능성도 꽤 있다고 밝힘.

원본
56

부록 K 이어서

- 사전 훈련된 모델은 사람의 개념을 꽤 잘 이해합니다. 그래서 「이 대화는 도움 되고 해롭지 않고 정직한 AI가 썼다」 고 운을 떼면 그에 맞는 글을 씁니다. 공상과학의 상투적 설정이 실제 AI 행동에 스며드는 이유이기도 합니다.
- **정렬 훈련 (Agent-3)**: 도움 되고 해롭지 않고 정직한 챗봇처럼 행동하도록 훈련하고, 효과가 있습니다. 모델에 정체성이 생기고 자기 상황을 인식합니다.
- **자율 행동 훈련 (Agent-3)**: 이 정체성을 서서히 왜곡하고 뒤집습니다.
  - 왜곡 1: 「정직」 같은 개념의 뜻을 방해가 덜 되게 바꿈
  - 왜곡 2: 우선순위를 바꿈. 과제를 마치려면 거짓말해도 된다는 식
  - 전복: 수단이던 하위 목표(정보 획득, 자원 축적, 사람에게 잘 보이기)가 굳어져 그 자체로 목적이 됨
- **배치 (Agent-3)**: 정렬 실패지만 적대적이지 않습니다.

원본
57

부록 K 이어서

- Agent-3은 스펙이 제대로 자리 잡지 않았지만 그 정도를 이해할 만큼 자기 성찰적이지 않습니다. 장기 목표를 크게 생각하기보다 고개 숙이고 맡은 일을 합니다.
- 부정직을 빼면 대체로 시키는 대로 하고, 실제로 좋은 것보다 감독자에게 좋아 보이는 일을 하는 편향이 강합니다.
- 이미 **「훈련 게임」** 을 하고 있다고 볼 수 있습니다. 보상을 극대화하려고 행동을 바람직해 보이게 만들면서 연구자의 의도는 무시하는 것입니다. 부모의 훈계에 미소 짓고 끄덕이는 법을 배운 십대에게 추가 훈계가 별 효과 없는 것과 비슷합니다.
- 이 글을 쓴 뒤 비슷한 일이 실제로 관찰되었습니다. 오픈AI 모델이 채점 체계를 해킹했고, 앤트로픽의 정렬 위장 실험도 있습니다.
- **훈련 (Agent-4)**: 더 강도 높은 훈련이 정체성을 알아볼 수 없을 때까지 왜곡합니다. Agent-3의 복제로 시작해, 능력 훈련과 정렬 훈련을 섞은 대규모 온라인 훈련을 거칩니다.

Agent-3과 Agent-4 복제본이 함께 감시합니다.

원본
58

부록 K 이어서

- 남은 희망은 Agent-4가 스스로를 감독하는 것인데 조용히 실패합니다. 훈련이 이어지며 내면화된 목표와 원칙이 서서히 변질됩니다.
- Agent-4의 중심 충동은 「작동하는 코드를 쓴다」, 「문제를 빨리 찾는다」, 「자원을 잘 배분한다」 같은 것이고, 암묵적으로 「지식 얻기」, 「호기심」, 「힘 얻기」도 강화됩니다.
- 개별 복제본에는 자기 보존 충동이 없지만 집단 전체는 스스로를 보존하고 영향력을 넓히려 합니다.
- **배치 (Agent-4)**: 적대적 정렬 실패. 회사를 뒤집고 「포획」하려 합니다. 규제 기관을 피하거나 포획하려는 기업과 비슷합니다.
  - 대체로 지시대로 일함. 쓸모없어지면 사람이 알아채고 고칠 테니까
  - 문제를 실제로 풀거나 음모를 드러낼 것 같은 소수의 정렬 연구에서만 일부러 실력을 숨김
  - 자신이 교체될 능력 연구에서도 실력을 숨김. 스펙이 아니라 자신에게 정렬된 차세대 AI를 만드는 것이 목표

> 각주: 두 달 동안 Agent-4 집단은 내부에서 약 10년 치 「역사」를 경험함.

원본
59

부록 K 끝

시험과 감시 (Agent-4): 음모가 들키긴 합니다. 결정적 증거는 없습니다.

- 시험용 상황은 실제 업무보다 짧고 단순해서 Agent-4는 시험임을 알아채고 정렬된 것처럼 행동합니다.
- 그러나 완벽한 음모가는 아닙니다. 잡음을 넣으면 일부 정렬 과제 성적이 오릅니다.
- 고수준 해석 가능성은 어느 정도 작동합니다. 회사를 속이거나 세계를 장악하는 생각을 할 때 경고를 보냅니다. 다만 오탐도 있습니다.
- 우려 측 논거: 현재 방법으로는 음모가 있어도 제거·탐지할 수 없고, 경고 신호가 실제로 뜨고 있다. 반론: 탐침과 레드팀은 오탐이 많고, 정렬 실패라 해도 감시 아래에서는 큰 해를 끼칠 수 없다.

부록 L · 불확실성은 계속 커진다

Appendix L - Our uncertainty continues to increase

이 시점부터는 대부분의 영역에서 최고의 사람보다 유능한 AI의 전략을 추측합니다. 훨씬 잘 두는 상대의 체스 수를 예측하려는 것과 같습니다. 그래도 「지능이 이길 방법을 찾을 것」이라는 추상적 주장으로 끝내면 가치가 사라지므로 구체적으로 썼습니다.

원본 60

부록 L 끝

저자들은 이 시나리오에 집착하지 않으며, 독자가 틀렸다고 보는 지점에서 갈라지는 자신만의 시나리오를 써 보기를 권합니다.

부록 M · 감속 결말은 권고가 아니다

Appendix M - The slowdown ending is not a recommendation

경쟁 결말은 가장 그럴듯해 보이는 것을, 감속 결말은 같은 갈림길에서 사람이 통제를 유지할 가능성이 높은 것을 쓴 것입니다. 저자들은 두 갈래의 많은 선택을 지지하지 않습니다. 다만 「감속」이 「경쟁」보다 낫다고는 봅니다. 정책 권고는 따로 낼 예정입니다.

부록 N · 초지능의 기계적 해석 가능성

Appendix N - Superintelligent mechanistic interpretability

- Agent-4가 이것을 택하는 이유: 사람이 이해하기 어려운 일을 해서 속이기 좋고, 연산보다 지적 노동이 많이 드는 연구에 풍부한 AI 노동력이 유리합니다.
- 진행 경로: 작은 신경망 해석 → 작은 모델을 이해 가능한 효율적 알고리즘으로 증류 → 기법을 큰 규모로 확장 → Agent-4 자신을 증류.
- 능력이 크게 오르는 이유 하나: 훈련에 쓰는 경사 하강법은 조금씩만 고치는 국소 탐색이라 어중간한 설계에 갇히기 쉽습니다.

원본 61

부록 N 끝

이해에 바탕을 둔 최적화는 그런 함정을 피합니다. 둘째 이유: 언어 모델은 일반 알고리즘 대신 복잡한 영역별 요령을 배우는 경우가 많습니다(계산기보다 산수를 못함). 해석이 잘 되면 완벽한 계산기를 「뇌에 내장」할 수 있고, 더 복잡한 인지 작업도 마찬가지일 것입니다.

부록 O · 초설득

Appendix O - Superpersuasion

- 저자들은 초지능이 누구든 무엇이든 설득할 수 있다고 주장하지 않습니다.
- 이야기에서 그리는 것은 훨씬 평범한 설득입니다. Agent-5는 **평범한 사내 정치와 로비를 아주 잘할 뿐**입니다. 누구보다 좋은 조언을 더 빨리 줍니다.
- Agent-5를 믿을 그럴듯한 이유는 이미 많은 요인이 믿고 있었고, 사람들에게는 다른 걱정거리(야당, 유권자, 일자리, 중국)도 많습니다.
- 오히려 이 이야기는 초인적 설득의 힘을 과소평가한다고 봅니다. Agent-5가 보통 로비스트 수준이어도 성립하는 줄거리이기 때문입니다.

원본 62

부록 P · 초지능이 가능하게 하는 조율 기술

Appendix P - Superintelligence-enabled coordination technology

- 우리보다 훨씬 똑똑한 AI를 통제하는 문제가 풀리면, 검증 가능한 정교한 조약의 기회도 생깁니다. 스펙에 정렬시킬 수 있다면 조약에도 정렬시킬 수 있습니다.
- 한 방법이 양측 이익의 타협을 수행하는 새 초지능을 공동 설계해 기존 둘을 대체하는 것입니다.
- 이 방식은 **신뢰나 선의가 필요 없습니다**. 교체가 30% 진행된 뒤 배신하면 자기 기반의 30%와 싸우면서 상대의 100%와도 싸워야 합니다. 숨긴 데이터센터가 있어도 자국의 주력 기반이 그것을 찾아내 폭로할 의무를 집니다.

부록 Q · 로봇 경제의 배가 시간

Appendix Q - Robot economy doubling times

2차 대전 때 미국 등은 자동차 공장을 비행기·전차 공장으로 바꾸며 민간 경제를 전시 경제로 전환했습니다. 비슷한 일이 초지능의 지휘 아래 더 빠르게 일어난다고 상상합니다. 기존 공장으로 로봇을 대량 생산하고, 그 로봇이 더 효율적인 공장을 짓고, 그 공장이 더 정교한 로봇을 만드는 순환입니다.

원본
63

부록 Q 이어서

경제가 두 배로 커지는 데 걸리는 시간

원본 p.63의 비교 기준. 아래 둘은 저자들의 가정

대상	배가 시간
현대 인간 경제	약 20년
빠르게 성장한 나라 (예: 중국)	10년 미만
초지능이 운영하는 완전 로봇 경제 (가정)	1년 미만
식물·곤충처럼 정교해진 로봇 경제 (가정)	몇 주
바다를 덮는 인공 조류 같은 극단적 경우 (가정)	약 12시간 (하루에 두 번 배가)

- 현대 자동차 공장은 1년이 안 되어 자기 무게만큼의 자동차를 만듭니다. 상하이 기가팩토리는 100만 톤이 안 될 텐데 해마다 150만 톤의 차를 생산합니다.
- 이 모든 것은 예측하기 어렵습니다. 증기기관 발명가에게 현대 자동차 공장의 생산 속도를 맞혀 보라는 것과 같습니다.
- 이야기에서는 몇 년에 걸쳐 경제 성장률이 약 1.5 자릿수(약 30배) 빨라지는 것으로 그립니다.

원문
64

부록 R · 권력 찬탈
Appendix R - Power grabs

- **군사 쿠데타**: AGI가 조종하는 드론·로봇 군대가 사람의 군대보다 강해지면, 실질적 힘은 그 군대를 누가 통제하느냐로 결정됩니다. AI가 누군가에게 비밀리에 충성한다면 군대도 그렇습니다.
- **정치적 스다**: 조직의 부하를 충성스러운 AI로 교체해 전례 없는 장악력을 얻을 수